

CENTRO DE ESTUDOS E SISTEMAS AVANÇADOS DO RECIFE - CESAR

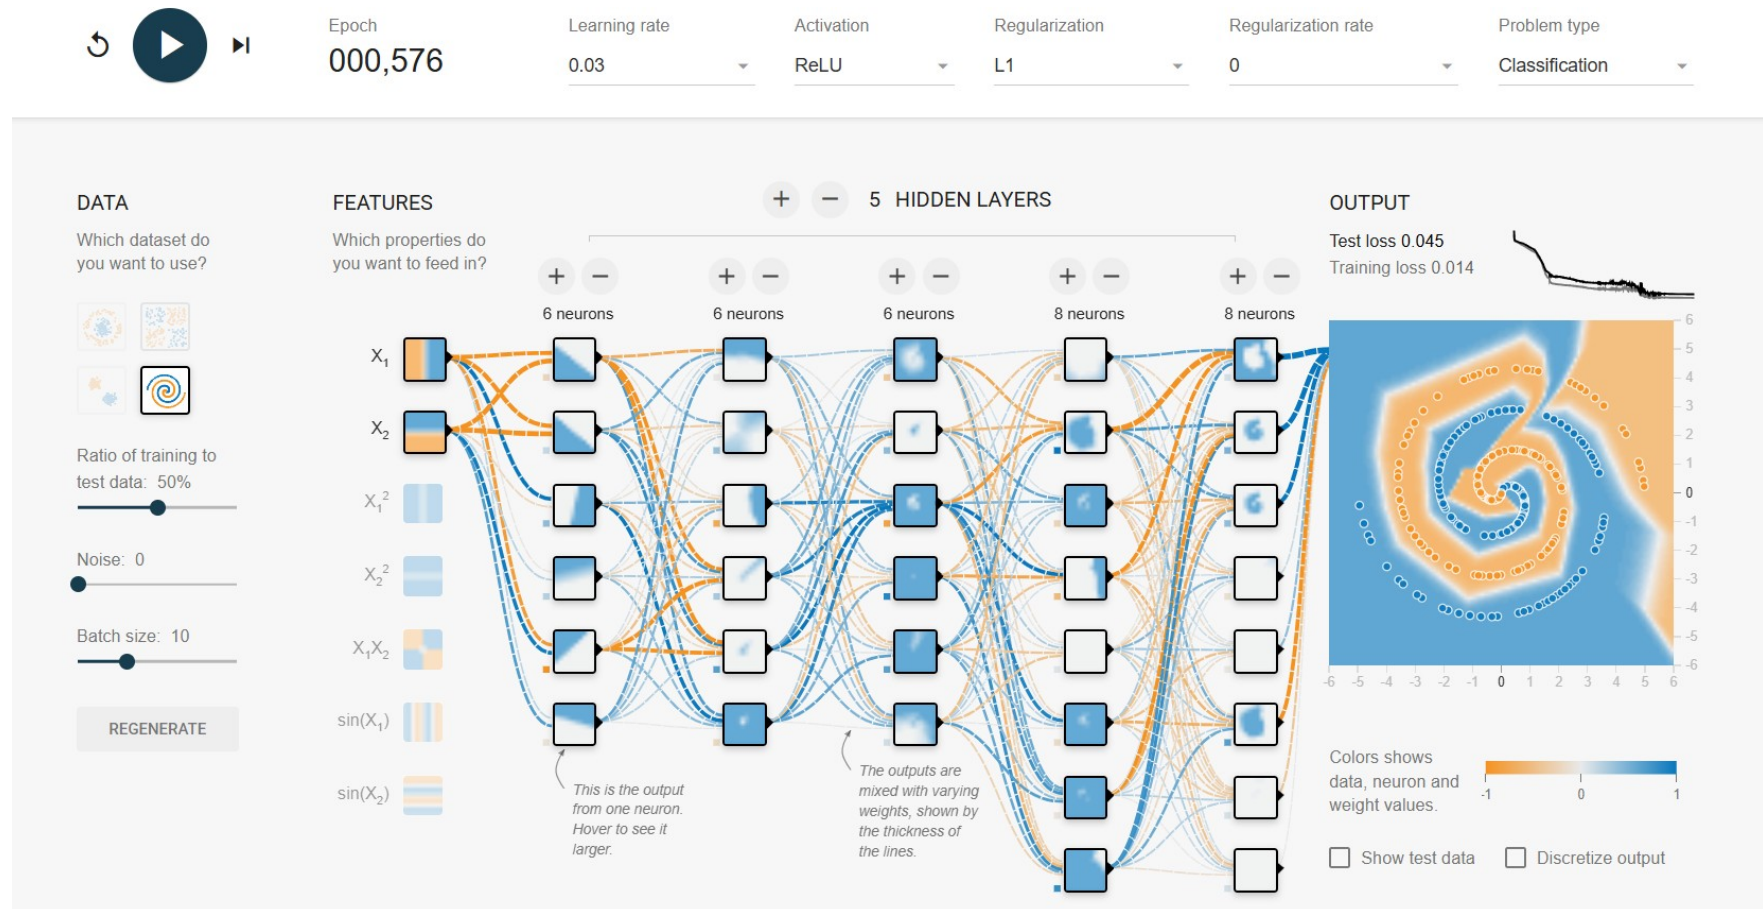
PÓS GRADUAÇÃO EM ENGENHARIA DE DADOS - TURMA 2025.1

DISCIPLINA: RNA/ DEEP LEARNING - ALUNO: WOLNEY LEITE MRANDA

1. Acesse a página <http://playground.tensorflow.org> e utilizando apenas 2 entradas (x_1 e x_2), procure variar os diversos parâmetros: número de camadas, número de neurônios em cada camada, tipo de ativação, learning rate e o fator de regularização. Resolva para o dataset "Spiral".

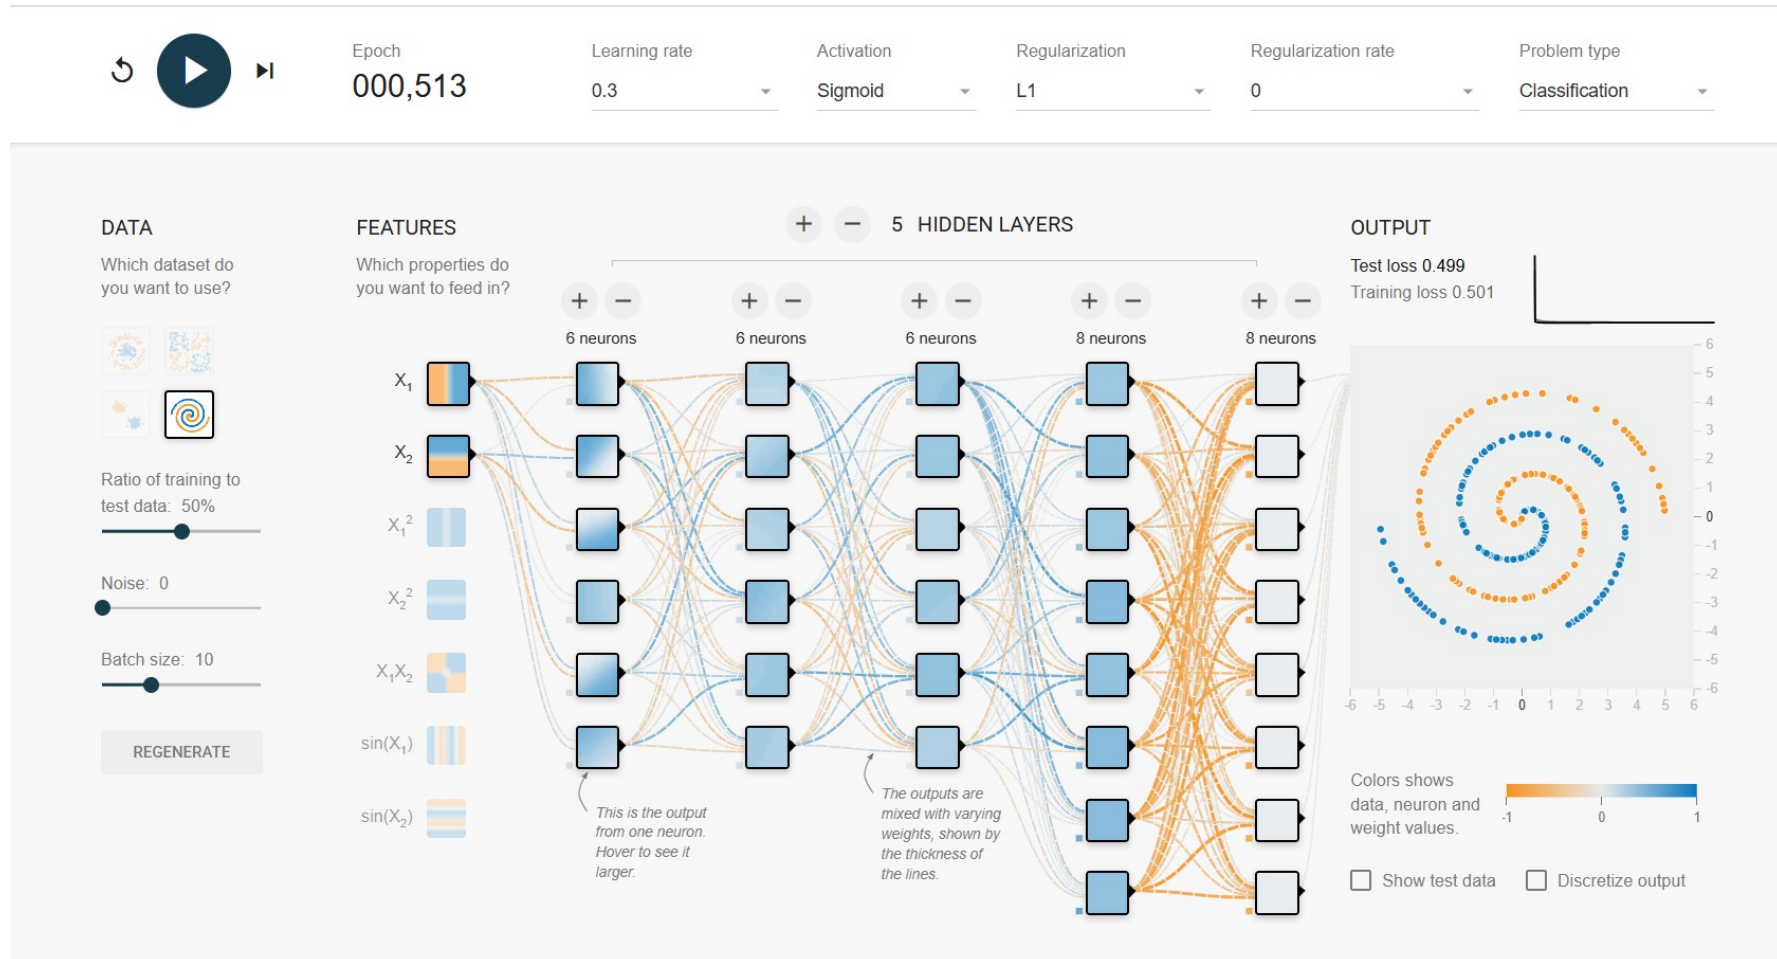
Os parâmetros foram mantidos constantes: número de Camadas Ocultas: 5 Ocultas; número de neurônios por Camada: 6-6-6-8-8 neurônios. Taxa de Aprendizagem (Learning Rate): 0.03. Problema e Dados: O tipo de problema é Classificação.

A) Imagem 1 - Print, utilizando função de ativação RELU



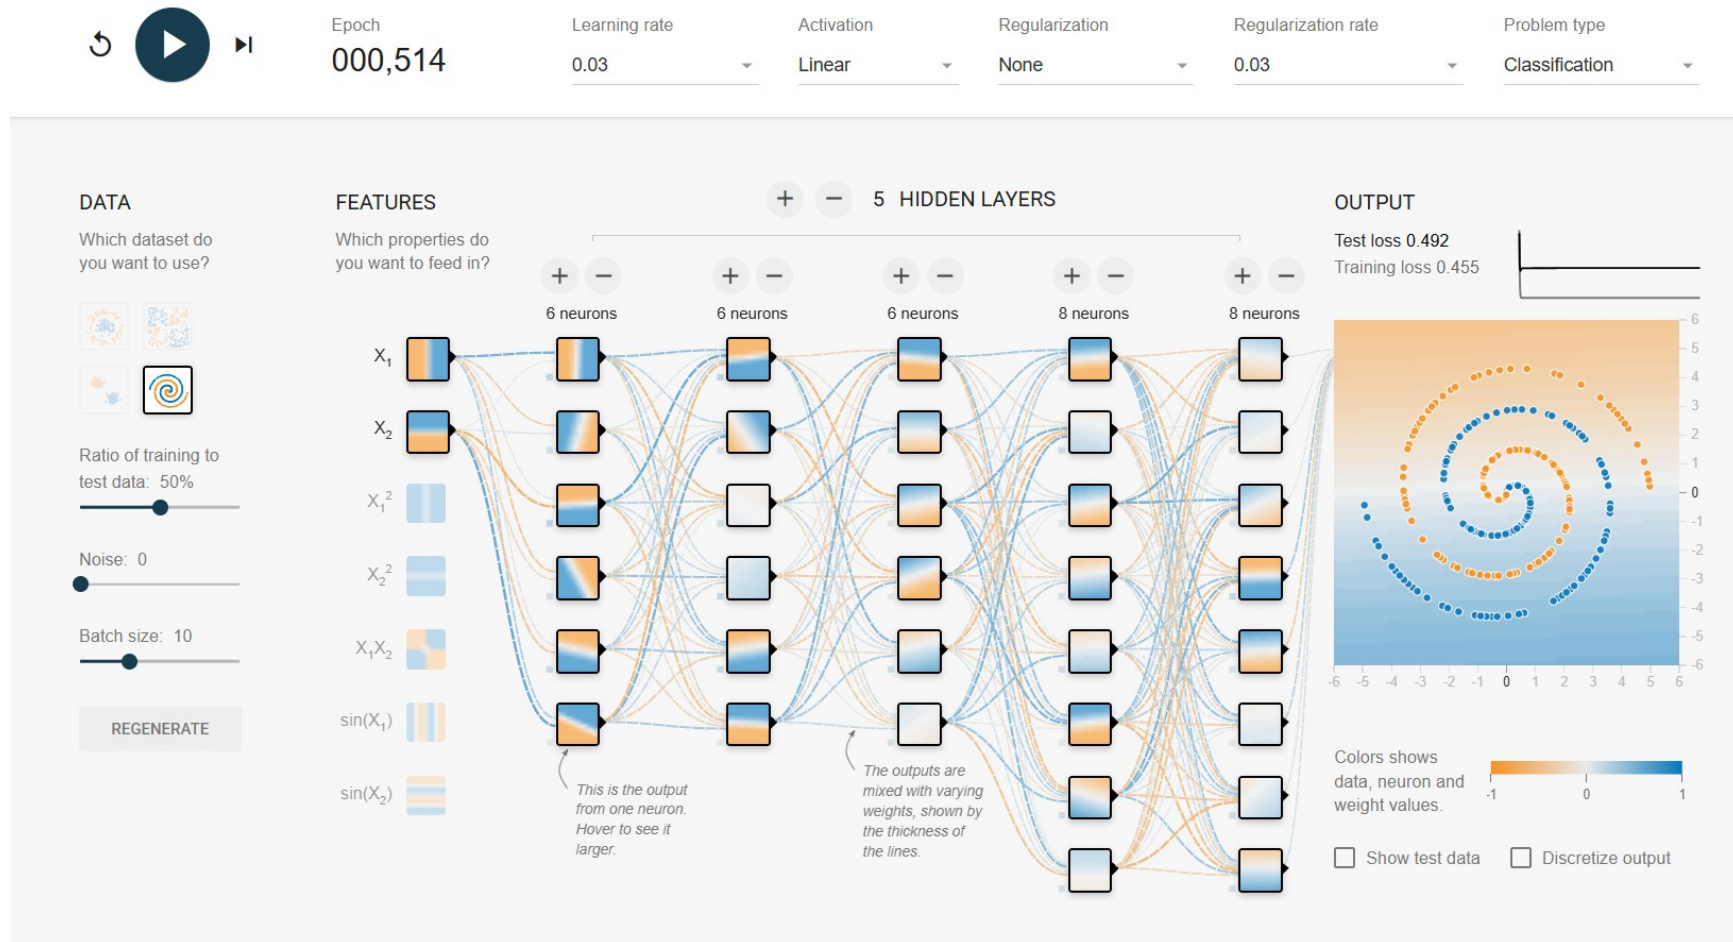
Apresentou um excelente desempenho (Test Loss aprox. 0,045). A ReLU resolve o problema da espiral de forma muito eficiente. Sua não-linearidade simples e o gradiente constante evitam problemas como o vanishing gradient, permitindo que a rede aprenda padrões complexos rapidamente.

B) Imagem 2 - Print, utilizando função de ativação Sigmoid



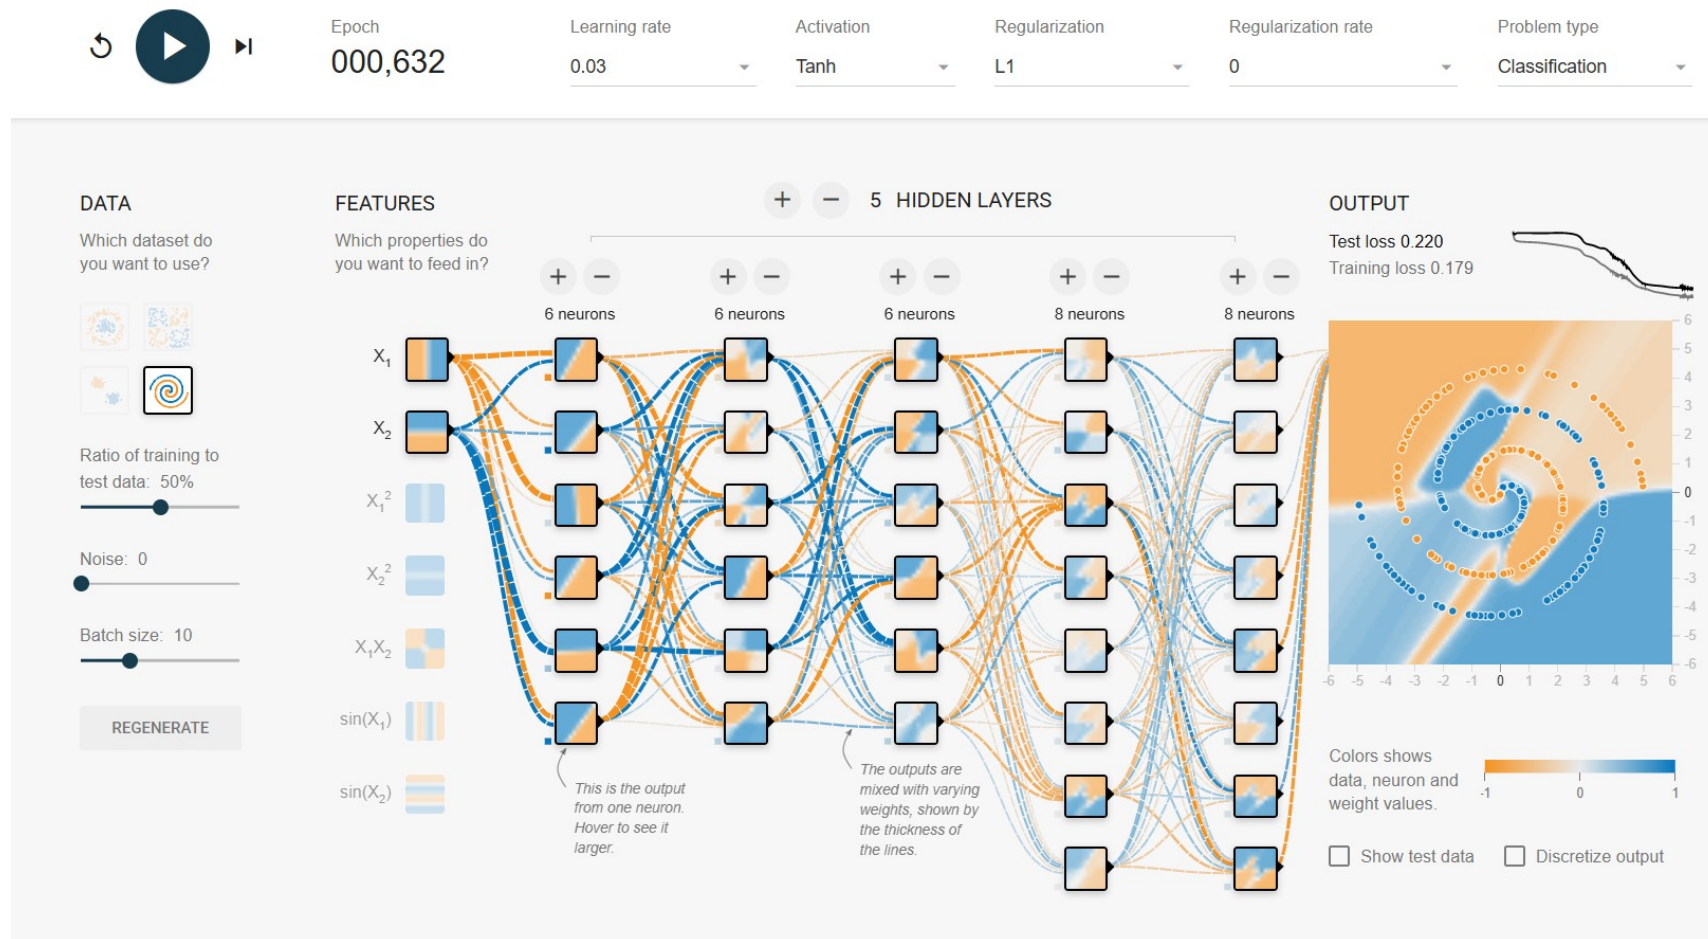
Apresentou um péssimo desempenho (Test Loss aprox. 0,50). A Sigmoid, apesar de não linear, é propensa ao problema do gradiente evanescente (vanishing gradient), especialmente com muitas camadas, o que impede o aprendizado.

c) Imagem 2 - Print, utilizando função de ativação Linear



Apresentou um péssimo desempenho (Test Loss aprox. 0,49). A função de ativação linear não foi capaz de resolver problemas não lineares complexos (como a espiral), não importando quantas camadas sejam usadas. A rede se comporta como uma regressão logística única.

D) Imagem 2 - Print, utilizando função de ativação Tanh



Apresentou um intermediário (Test Loss aprox. 0,22). Melhor que Linear e Sigmoid, mas significativamente pior que ReLU. A Tanh tem um desempenho melhor que a Sigmoid, mas ainda pode sofrer com a saturação do gradiente.

CONCLUSÃO

- A melhor solução encontrada para o dataset "Spiral" foi a configuração com a função de ativação ReLU (imagem 1) é a única que atinge um alto desempenho (baixo loss e excelente separação visual), demonstrando a importância crítica da não-linearidade no tratamento de dados complexos com múltiplos neurônios e camadas.
- A regularização e a taxa de aprendizagem (quando fixadas) não tiveram um impacto significativo na resolução do problema em comparação com a ativação.